

AI Summary

제품 요구사항 문서 (PRD)

100% 로컬 문서 RAG Q&A + 실시간 회의 전사 · 회의록 데스크톱 앱

버전 0.1 (MVP) · 프라이버시 우선 · 클라우드 전송 0

작성일: 2026-07-08

1. 제품 개요

AISummary 는 사용자의 PC 안에서 100% 로컬로 동작하는 프라이버시 우선 데스크톱 앱이다. 두 가지 핵심 가치를 제공한다: (1) 지정한 폴더의 문서를 자동으로 벡터화해 근거를 인용하는 문서 Q&A를 제공하고, (2) 회의를 실시간 전사해 요약·회의록 PDF를 자동 생성한다. 모든 데이터·모델·추론이 로컬에 머물러 외부 네트워크로 나가는 트래픽이 없다.

타겟 사용자는 계약서·보고서·회의록 같은 민감 문서를 클라우드에 올릴 수 없는 개인·소규모 팀·전문직(법무·의료·연구)이다. 저사양 노트북에서도 동작하도록 하드웨어를 감지해 모델을 자동 선택한다.

한 줄 정의

"내 문서와 회의를, 인터넷 없이, 근거와 함께 답해주는 로컬 AI 비서"

해결하는 문제

- 프라이버시 — 민감 문서를 클라우드 AI에 올리는 것이 규정·보안상 불가능한 사용자가 많다.
- 할루시네이션 — 일반 LLM은 문서에 없는 내용을 그럴듯하게 지어낸다. 근거 추적이 안 된다.
- 회의 기록 부담 — 실시간 전사·요약·회의록 작성이 수작업이거나 클라우드 서비스에 의존한다.
- 비용·의존성 — 구독형 SaaS는 지속 비용이 들고 인터넷·계정에 종속된다.

2. 제품 목표 & 성공 지표

MVP가 달성해야 할 측정 가능한 목표다.

#	목표	성공 기준 (측정 가능)
G1	폴더 문서 자동 벡터화 → 로컬 DB	파일 추가 후 30초 내 검색 가능, 100% 오프라인
G2	저사양 노트북에서 RAG Q&A	12GB RAM에서 첫 토큰 < 3초, 인용 100% 표기
G3	할루시네이션 억제	근거 없으면 "모름" 응답, 모든 사실 문장에 출처 연결
G4	실시간 회의 전사 + 회의록 PDF	전사 지연 < 2초, 종료 후 60초 내 PDF 생성
G5	하드웨어 감지 → 모델 자동 선택	3개 이상 티어, 사용자 오버라이드 가능
G6	품질·보안 리뷰 게이트	자동 점수 < 85 또는 보안 감점 시 릴리스 차단

비목표 (Non-goals, MVP 범위 밖)

- 멀티유저 서버 / 팀 협업 동기화
- 클라우드 백업·동기화
- 모바일 앱
- 모델 파인튜닝

3. 사용자 & 핵심 시나리오

페르소나	니즈	핵심 시나리오
법무 · 계약 담당	외부 유출 불가한 계약서 검토	"이 계약 만료일은?" → 원문 페이지 · 구절 인용과 함께 답변
연구자 · 전문직	논문 · 자료 근거 기반 질의	폴더 통째로 인덱싱 후 자연어로 검색 · 요약
PM · 팀 리드	회의 기록 · 액션아이템 정리	회의 실시간 전사 → 종료 시 요약 · 액션아이템 PDF 자동 생성

대표 사용자 여정

- 설치 → 앱이 하드웨어를 감지하고 적합한 모델 티어를 추천 → 사용자 확인 시 모델 다운로드.
- 문서 연결 → 감시할 폴더 선택 → 자동으로 문서 벡터화 · 인덱스 상태 표시.
- 질문 → 자연어로 질문 → 근거 인용이 달린 답변, 인용 클릭 시 원문 하이라이트 미리보기.
- 회의 → "회의 시작" → 라이브 자막 확인 → "종료 & 요약" → 회의록 PDF · Markdown 저장.

4. 핵심 기능 요구사항

4.1 문서 인제스천 (벡터화)

- 지정 폴더를 실시간 감시(watchdog)해 생성 · 수정 · 삭제를 자동 반영.
- SHA - 256 해시 + 수정시각으로 변경분만 재처리 — 재시작해도 중복 인덱싱 없음.
- 지원 포맷: PDF, DOCX, PPTX, TXT/MD, HTML, CSV, 한글 HWP/HWPX.
- 페이지 단위로 파싱해 각 청크에 파일 · 페이지 · 문자 위치 메타 부착 → 인용 근거로 사용.
- 로컬 벡터 DB(LanceDB)에 저장, 삭제 파일은 인덱스에서 제거.

4.2 근거 인용 RAG Q&A (할루시네이션 억제 핵심)

- 하이브리드 검색: 벡터(의미) 검색 + BM25(키워드) 결과를 순위 융합(RRF)으로 결합.
- 신뢰도 게이팅: 검색 유사도가 임계값 미만이면 답변 대신 "찾을 수 없습니다" 거부.
- 인용 강제: 모든 사실 문장에 [S1] 형식 출처 표기, 제공된 출처만 사용하도록 지시.
- 후검증: 생성된 인용이 실제 검색 출처에 존재하는지, 인용 없는 문장이 있는지 자동 검사.
- 낮은 temperature(0.2)로 창작 억제, 답변은 스트리밍으로 표시.
- 인용 클릭 시 원본 PDF 페이지를 이미지로 렌더하고 해당 구절을 하이라이트.

4.3 실시간 회의 전사 & 회의록

- 마이크 또는 시스템 소리(loopback) 캡처 → faster-whisper로 실시간 전사.
- WebSocket으로 라이브 자막 스트리밍, 진행 중 요약 · 제목 자동 제안.
- 종료 시 SLM이 요약 · 주요주제 · 결정사항 · 액션아이템을 구조화 JSON으로 생성.
- 회의록을 Markdown + PDF로 출력(한글 폰트 지원), 액션아이템은 담당 · 기한 표로 렌더.
- (옵션) 화자 분리(pyannote)로 발화자 태깅.

4.4 하드웨어 감지 & 모델 자동 선택

- RAM · CPU · GPU(NVIDIA/Apple Silicon)를 감지해 Low/Mid/High 3개 티어로 자동 매핑.
- 티어별로 LLM · 임베딩 · STT 모델과 컨텍스트 길이 · top-k · 청크 크기를 자동 세팅.
- 사용자가 UI에서 티어 · 파라미터를 오버라이드 가능.

모델 티어 정의

티어	조건 (RAM / GPU)	LLM	임베딩	STT	리랭커 · 화자분리
Low	< 12GB, GPU 없음	Gemma 4 E2B	all - MiniLM	Whisper tiny	끔
Mid	12 - 24GB 또는 6GB+ VRAM	Gemma 4 E4B	nomic - embed	Whisper base	옵션
High	24GB+ / 8GB+ VRAM	Gemma 4 E4B	Qwen3 - Emb ed	Whisper small	둘 다 켜

4.5 로컬 서비스 & 보안

- FastAPI가 127.0.0.1 전용 바인딩 + 세션 토큰 인증 + CORS 잠금으로 동작.
- 파일 열기 · 탐색기 표시는 인덱싱된 파일 · 감시 폴더로만 제한(경로 탈출 방어).
- 텔레메트리 기본 OFF(옵트인), 모든 데이터는 사용자 홈 디렉터리에 저장.
- 백엔드 2중 지원: llama - cpp - python 인프로세스 GGUF(기본, 데몬 불필요) / Ollama.

5. 비기능 요구사항 (NFR)

영역	요구사항
성능	첫 토큰 < 3초(12GB RAM), 전사 지연 < 2초, 파일 추가 후 30초 내 검색 가능
프라이버시	외부 네트워크 트래픽 0, 모든 데이터 · 추론 로컬, 텔레메트리 기본 OFF
호환성	저사양 노트북(CPU - only, < 12GB RAM)부터 GPU 워크스테이션까지 티어로 대응
신뢰성	크래시 시 자동 재시작 슈퍼바이저, 세션 토큰 영속화로 재시작 후에도 연결 유지
보안	로컬 바인딩 · 토큰 인증 · 경로 제한, pip - audit 의존성 취약점 스캔
품질 게이트	골든셋 RAG 점수 ≥ 85 그리고 보안 감점 0이어야 릴리스

6. 품질 측정 & 릴리스 게이트

빌드마다 자동 채점 → 임계값 미달 시 릴리스 차단. 점수는 가중 합(100점 만점)이며, 미달 항목은 다음 스프린트 백로그로 자동 복귀한다.

영역	측정 항목	배점
RAG 품질	groundedness, 인용 정확도, 거부 정확도, 답변 관련성 (골든셋)	30
회의 품질	전사 정확도(WER), 요약 충실도	20
성능	첫 토큰 지연, 인제스천 처리량, 메모리 상한 준수	15
보안	pip - audit 무결점, 네트워크 격리 · 인증 · CORS 테스트 통과	20
안정성	유닛 · 통합 테스트 통과율, 크래시프리 세션	15

7. 릴리스 로드맵

마일스톤	범위	상태
M0 (현재)	백엔드 코어 — 하드웨어 감지, 인제스천, RAG 엔진, 회의 스캐폴드, FastAPI	완료
M1	실 임베딩/모델 연결, 골든셋 평가 하니스, 후검증 완성	완료
M2	실시간 전사(WebSocket) + 화자분리 + PDF 회의록	완료
M3	Tauri UI 셸 + 설치 마법사(하드웨어 감지 흐름) + 트레이 앱	진행
M4	리뷰 게이트 자동화(CI) + 패키징 · 인스톨러 + 성능 튜닝	예정

8. 주요 리스크 & 가정

- 모델 성능 — 저사양 SLM(Gemma 4 E2B)이 복잡한 질의에서 품질이 낮을 수 있음. 완화: 추출형 폴백 · 신뢰도 게이팅.
- 전사 정확도 — CPU에서 Whisper tiny/base는 잡음 · 다인 발화에서 WER이 높을 수 있음.
- 설치 장벽 — 모델 다운로드 용량 · 시간. 완화: 티어별 최소 모델 · 백그라운드 다운로드.
- 가정 — 사용자 PC가 최소 8GB RAM 이상이며 문서가 텍스트 추출 가능한 형식임.

본 PRD는 AISummary v0.1 코드베이스와 아키텍처 설계 문서를 근거로 작성되었으며, 제품 진화에 따라 갱신된다.